

# Dvojni bootstrap z diagnostičnimi testi

Enej Hudobreznik

Univerzitetni študijski program Računalništvo in informatika

Fakulteta za računalništvo in informatiko

Mentor: prof. dr. Erik Štrumbelj

Copyright: To delo je ponujeno pod licenco CC-BY-4.0.

## Abstract

### Ključne besede

Uvod

## 1. Intervali zaupanja bootstrap in kalibracija

V inferenčni statistiki na podlagi vzorca  $\mathbf{X} = (X_1, \dots, X_n)$  iz porazdelitve  $F$  sklepamo o parametru populacije  $\theta = T(F)$ , kjer je  $T$  statistični funkcional porazdelitve (npr. povprečje ali mediana).

Parameter  $\theta$  ocenimo s točkovno oceno  $\hat{\theta} = s(\mathbf{X})$ , ki je slučajna spremenljivka, saj je njena vrednost odvisna od naključnega vzorca iz populacije. Sama vrednost  $\hat{\theta}$  ne pove, kako daleč od vrednosti  $\theta$  utegne biti. Da to negotovost kvantificiramo, uporabljamo intervale zaupanja.

**Definicija 1** ([1, razd. 6.3.2]). *Interval zaupanja* za parameter  $\theta$  pri stopnji zaupanja  $1 - \alpha$  je interval  $\mathcal{I}_{1-\alpha}(\mathbf{X}) = [L(\mathbf{X}), U(\mathbf{X})]$ , za katerega velja

$$\Pr_{\theta}(\theta \in \mathcal{I}_{1-\alpha}(\mathbf{X})) \geq 1 - \alpha, \quad \text{za vse } \theta \in \Theta.$$

Verjetnost

$$\Pr_{\theta}(\theta \in \mathcal{I}_{1-\alpha}(\mathbf{X}))$$

imenujemo *verjetnost pokritja* (angl. *coverage probability*) [2, def. 9.1.4] in je v splošnem odvisna od  $\theta$ . Pogoji v definiciji 1 torej zahteva, da je verjetnost pokritja vsaj  $1 - \alpha$ , ne glede na vrednost  $\theta$ .

V nadaljevanju se pri opisu metod osredotočamo na *enostranske* intervale zaupanja oblike  $(-\infty, U(\mathbf{X})]$ .

**1.1. Percentilni bootstrap.** Intervale zaupanja pogosto izračunamo na podlagi asimptotične porazdelitve vzorčne statistike  $\hat{\theta}$ , ki velja za velike vzorce ( $n \rightarrow \infty$ ). Pri majhnih vzorcih je lahko aproksimacija neustrezna, za mnoge statistike pa porazdelitve  $\hat{\theta}$  brez dodatnih predpostavk ni mogoče analitično izpeljati.

Alternativo klasičnim inferenčnim metodam ponuja metoda *bootstrap* [3, 4]. Za izračun intervalov zaupanja lahko uporabimo *percentilno metodo* [5].

Naj bo  $\mathbf{x} = (x_1, \dots, x_n)$  realizacija vzorca iz populacije  $F$  in  $\theta = T(F)$  parameter, ki nas zanima. Iz opazovanega vzorca tvorimo *empirično porazdelitveno funkcijo*:

$$\hat{F}_n(t) := \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x_i \leq t\}}. \quad (1)$$

Percentilni interval zaupanja temelji na *porazdelitvi bootstrap*

$$\hat{G}(t) := \Pr^*(\hat{\theta}^* \leq t), \quad \hat{\theta}^* = T(\hat{F}_n^*),$$

kjer je  $\hat{F}_n^*$  empirična porazdelitvena funkcija *vzorca bootstrap*  $\mathbf{x}^*$ , vzorčenega iz  $\hat{F}_n$ , in  $\Pr^*(\cdot)$  pripadajoča verjetnost.

Zgornjo mejo intervala pri stopnji zaupanja  $\gamma$  (npr.  $1 - \alpha$ ) izračunamo kot  $\gamma$ -kvantil porazdelitve bootstrap:

$$\hat{\theta}_{pb}[\gamma] := \hat{G}^{-1}(\gamma) = \inf\{t : \hat{G}(t) \geq \gamma\}. \quad (2)$$

Ker  $\hat{G}$  običajno ne moremo izračunati, jo ocenimo z metodo *Monte Carlo*. Iz  $\hat{F}_n$  neodvisno vzorčimo  $B$  vzorcev bootstrap velikosti  $n$  in za vsak vzorec izračunamo *replikacijo bootstrap*  $\hat{\theta}_b^* = T(\hat{F}_{n,b}^*)$ ,  $b = 1, \dots, B$ . Empirična porazdelitev

$$\hat{G}_B(t) := \frac{1}{B} \sum_{b=1}^B \mathbf{1}_{\{\hat{\theta}_b^* \leq t\}}$$

Double bootstrap with diagnostic tests

Abstract

Keywords

aproximira  $\widehat{G}$ . Empirične kvantile v implementaciji ocenimo s cenilko, ki je približno nepristranska v smislu mediane (angl. *median-unbiased*), kot je priporočeno v [6].

Pristop s ponovnim vzorčenjem iz empirične porazdelitvene funkcije, definirane v (1), imenujemo *neparametrični bootstrap*. Ob kršitvi predpostavke o neodvisnih in enako porazdeljenih (*i.i.d.*) podatkih (npr. pri časovnih vrstah, hierarhičnih podatkih) lahko uporabimo prilagojene sheme vzorčenja, opisane v [7] in [8, razd. 11.3].

Če za populacijo privzamemo parametrični model  $F_{\lambda}$ , lahko na podlagi vzorca ocenimo parametre modela  $\lambda$  in vzorčimo iz  $F_{\hat{\lambda}}$  (*parametrični bootstrap*).

V nekaterih primerih namesto ponovnega vzorčenja iz podatkovne množice ali iz parametričnega modela ponovno vzorčimo rezidualne, izračunane na podlagi modela, prilagojenega na podatkovni množici (*semiparametrični bootstrap*).

V nadaljevanju zaradi enotne notacije uporabljamo oznaki  $\widehat{F}$  za ocenjeni model populacije in  $\widehat{F}^*$  za njegovo različico bootstrap.

**1.2. Dvojni percentilni bootstrap.** Pristop iz razdelka 1.1 je preprost in v praksi pogosto uporabljen, vendar tipično ne doseže natančnosti naprednejših metod (npr. metode  $BC_a$ , opisane v [4, pogl. 14]). V okviru modela, navedenega v [9, razd. 2.4], natančnost metode teoretično opišemo z *redom napake verjetnosti pokritja*. Zanima nas predvsem, kako hitro se dejanska verjetnost pokritja približuje *nominalni* (tj. želeni), ko se velikost vzorca povečuje. Pravimo, da je percentilni interval zaupanja *natančen prvega reda* [10, en. 2.2]:

$$\pi_{pb}(\gamma) := \Pr_{\theta}(\theta \leq \hat{\theta}_{pb}[\gamma]) = \gamma + O(n^{-1/2}),$$

kjer je  $\gamma$  nominalna verjetnost pokritja,  $n$  pa velikost vzorca. Empirični rezultati v [11] poleg navedene asimptotične lastnosti kažejo, da je percentilni interval pri majhnih vzorcih praviloma manj natančen od naprednejših metod.

Natančnost percentilne metode lahko izboljšamo s *kalibracijo* stopnje zaupanja [4, razd. 18.3] in [12, razd. 5.6], kjer je naš cilj najti tako vrednost  $\beta$ , da bo dejanska verjetnost pokritja enaka  $\gamma$ :

$$\pi_{pb}(\beta) = \gamma.$$

V praksi  $\beta$  ne moremo izračunati neposredno, ker populacijske porazdelitve  $F$  ne poznamo. Kalibrirano stopnjo  $\hat{\beta}$  lahko tedaj ocenimo z metodo bootstrap na podlagi pogoja

$$\hat{\pi}_{pb}(\hat{\beta}) = \gamma, \quad \hat{\pi}_{pb}(\beta) := \Pr^*(\hat{\theta} \leq \hat{\theta}_{pb}^*[\beta]), \quad \hat{\theta} = T(\widehat{F}). \quad (3)$$

Zgornjo mejo  $\hat{\theta}_{pb}^*[\beta]$  izračunamo kot  $\beta$ -kvantil porazdelitve bootstrap vzorca  $\mathbf{x}^*$ :

$$\hat{\theta}_{pb}^*[\beta] := (\widehat{G}^*)^{-1}(\beta), \quad \widehat{G}^*(t) := \Pr^{**}(\hat{\theta}^{**} \leq t \mid \mathbf{x}^*), \quad \hat{\theta}^{**} = T(\widehat{F}^{**}),$$

kjer je  $\widehat{F}^{**}$  model, ocenjen na podlagi vzorca bootstrap  $\mathbf{x}^{**}$ , vzorčenega iz  $\widehat{F}^*$ , in  $\Pr^{**}(\cdot \mid \mathbf{x}^*)$  pripadajoča verjetnost.

Pogoj (3) razpišemo:

$$\hat{\pi}_{pb}(\beta) = \Pr^*(\hat{\theta} \leq \hat{\theta}_{pb}^*[\beta]) = \Pr^*(\hat{\theta} \leq (\widehat{G}^*)^{-1}(\beta)) = \Pr^*(\widehat{G}^*(\hat{\theta}) \leq \beta) = \gamma,$$

kjer v predzadnjem koraku predpostavimo, da je  $\widehat{G}^*$  zvezna in strogo naraščajoča. V splošnem je kvantilna funkcija definirana kot posplošeni inverz porazdelitvene funkcije (2), zaradi česar dogodka

$$\{\hat{\theta} \leq (\widehat{G}^*)^{-1}(\beta)\} \text{ in } \{\widehat{G}^*(\hat{\theta}) \leq \beta\}$$

nista nujno ekvivalentna. Predpostavka zveznosti in stroge monotonosti omogoči uporabo običajnega inverza ter s tem poenostavi izpeljavo. Pri končnih vzorcih in oceni porazdelitve bootstrap z metodo Monte Carlo je porazdelitvena funkcija stopničasta in zato predpostavka zveznosti ni izpolnjena. Kljub temu izpeljava vodi do uporabnega algoritma za praktično oceno kalibrirane stopnje zaupanja.

Označimo

$$u := \widehat{G}^*(\hat{\theta}).$$

Pogojno na realizirani vzorec  $\mathbf{x}$  je  $\hat{\theta}$  konstanta, slučajnost spremenljivke  $u$  pa izvira iz vzorca bootstrap  $\mathbf{x}^* \sim \widehat{F}$ , saj je funkcija  $\widehat{G}^*$  od njega odvisna. Takšno transformacijo imenujemo *predpivotiranje* (angl. *prepivotting*) [13].

Zgornjo mejo intervala pri stopnji zaupanja  $\gamma$  izračunamo kot:

$$\hat{\theta}_{db}[\gamma] := \hat{\theta}_{pb}[\hat{\beta}], \quad \hat{\beta} = u^{(\gamma)},$$

kjer je  $u^{(\gamma)}$   $\gamma$ -kvantil porazdelitve slučajne spremenljivke  $u$ .

Dvojni percentilni interval zaupanja je *natančen drugega reda* [9, razd. 3.11.3]:

$$\pi_{db}(\gamma) = \gamma + O(n^{-1}),$$

kar je enak red natančnosti, kot ga zagotavlja pogosto priporočena metoda  $BC_a$  [10, razd. 2.3].

Praktičen algoritem temelji na metodi Monte Carlo. Z zunanjimi  $B$  vzorci velikosti  $n$  iz  $\hat{F}$  ocenimo porazdelitev bootstrap  $\hat{\theta}^*$  in porazdelitev slučajne spremenljivke  $u$ . Posamezen  $u_b$ ,  $b = 1, \dots, B$ , ocenimo na podlagi  $C$  vgnezenih vzorcev velikosti  $n$  iz  $\hat{F}_b^*$ . Celoten postopek je podan v algoritmu 1.

Časovna zahtevnost algoritma je zaradi vgnezdene strukture reda  $O(BC\tau + B \log B)$ , kjer  $\tau$  predstavlja čas, potreben za vzorčenje iz porazdelitve, oceno modela na podlagi vzorca ter izračun statističnega funkcionala  $T$ . Drugi člen predstavlja časovno zahtevnost ocene empiričnih kvantilov, ki zahteva urejanje. Kljub visoki časovni zahtevnosti je ugodno, da so iteracije zanke med seboj neodvisne, zato je algoritem preprosto paralelizirati.

---

**Algoritem 1.** Dvojni percentilni bootstrap

---

**Require:** Realizacija vzorca  $\mathbf{x}$ , statistični funkcional  $T$ , stopnja zaupanja  $\gamma \in (0, 1)$ , število vzorcev na prvem nivoju  $B > 0$ , število vzorcev na drugem nivoju  $C > 0$

**Ensure:** Interval zaupanja  $(-\infty, \hat{\theta}_{\text{db}}[\gamma]]$

---

```

1: procedure DVOJNIPERCENTILNIBOOTSTRAP( $\mathbf{x}, T, \gamma, B, C$ )
2:    $\hat{F} \leftarrow$  model, ocenjen na podlagi  $\mathbf{x}$ 
3:    $\hat{\theta} \leftarrow T(\hat{F})$ 
4:   for  $b \leftarrow 1, \dots, B$  do
5:      $\mathbf{x}_b^* \sim \hat{F}$  ▷ Vzorec velikosti  $n$ 
6:      $\hat{F}_b^* \leftarrow$  model, ocenjen na podlagi  $\mathbf{x}_b^*$ 
7:      $\hat{\theta}_b^* \leftarrow T(\hat{F}_b^*)$ 
8:     for  $c \leftarrow 1, \dots, C$  do
9:        $\mathbf{x}_{b,c}^{**} \sim \hat{F}_b^*$  ▷ Vzorec velikosti  $n$ 
10:       $\hat{F}_{b,c}^{**} \leftarrow$  model, ocenjen na podlagi  $\mathbf{x}_{b,c}^{**}$ 
11:       $\hat{\theta}_{b,c}^{**} \leftarrow T(\hat{F}_{b,c}^{**})$ 
12:       $u_b \leftarrow \frac{1}{C} \sum_{c=1}^C \mathbf{1}_{\{\hat{\theta}_{b,c}^{**} \leq \hat{\theta}\}}$ 
13:    $\hat{\beta} \leftarrow$  empirični  $\gamma$ -kvantil porazdelitve  $\{u_b\}_{b=1}^B$ 
14:    $\hat{\theta}_{\text{db}}[\gamma] \leftarrow$  empirični  $\hat{\beta}$ -kvantil porazdelitve  $\{\hat{\theta}_b^*\}_{b=1}^B$ 
15:   return  $(-\infty, \hat{\theta}_{\text{db}}[\gamma]]$ 

```

---

## 2. Implementacija v Pythonu

**2.1. Obstoječe rešitve.** Številne metode za izračun intervalov zaupanja bootstrap v Pythonu so implementirane v uveljavljenih knjižnicah za podatkovno znanost, kot sta SciPy [14] in arch [15]. Knjižnica arch poleg osnovnega neparametričnega bootstrapa za i.i.d. podatke podpira tudi pogosto uporabljene pristope za neparametrično ponovno vzorčenje časovnih vrst ter parametrični in semiparametrični bootstrap. Nobena od omenjenih knjižnic pa ne implementira dvojne percentilne metode.

Edina nam znana javno dostopna implementacija te metode v Pythonu je del knjižnice bootstrap-ci [16]. Ta podpira neparametrično ponovno vzorčenje i.i.d. podatkov ter po eno parametrično in neparametrično metodo ponovnega vzorčenja hierarhičnih podatkov. Čeprav njen programski vmesnik sprejme poljubno uporabniško definirano statistiko, je dvojna metoda pri večjih vzorcih ( $n > 100$ ) oziroma večjem številu bootstrap ponovitev ( $B \geq 500$  ali  $C \geq 500$ ) zaradi samodejne uporabe JIT prevedene implementacije s knjižnico Numba [17] omejena na šest vnaprej določenih statistik. Podano seme generatorja psevdonaključnih števil pri uporabi te implementacije ne zagotavlja ponovljivosti rezultatov. Knjižnica ne podpira vzporednega izvajanja na več procesorskih jedrih in uporabniku ne omogoča, da bi sam definiral dodatne sheme ponovnega vzorčenja.

**2.2. Razvita knjižnica.** V okviru tega dela smo razvili knjižnico za Python, ki implementira dvojno percentilno metodo za izračun intervalov zaupanja. Knjižnica dodatno podpira oceno pristranskosti in variance z metodo bootstrap ter konstrukcijo običajnih percentilnih intervalov.

Knjižnica omogoča uporabo poljubnih uporabniško definiranih statistik nad polji NumPy [18] in podatkovnimi okvirji Pandas [19]. Izvajanje v več procesih in, kadar je mogoče, na več procesorskih jedrih, je podprto s knjižnico Joblib [20]. Podporo za vektorske statistike, ki jih obravnavamo po komponentah, in vektorizirano računanje vrednosti statistik na več vzorcih bootstrap hkrati nudi knjižnica NumPy. Ob določitvi semena generatorja psevdonaključnih števil knjižnica zagotavlja ponovljivost rezultatov, ne glede na izbrano število procesov.

**2.2.1. Zasnova.** Metodo bootstrap lahko v grobem razdelimo na dva koraka. V prvem na podlagi izvirnega vzorca generiramo vzorce bootstrap. V drugem na vsakem izmed njih izračunamo vrednost izbrane statistike ter dobljeno porazdelitev bootstrap uporabimo za izračun intervalov zaupanja, pristranskosti ali variance.

Takšni delitvi sledi tudi zasnova razvite knjižnice. Sheme ponovnega vzorčenja predstavljajo razredi, izpeljani iz abstraktnega razreda **Resampler**, medtem ko so metode za izračun intervalov zaupanja ter oceno variance in pristranskosti del razreda **Bootstrap**.

Takšna zasnova omogoča razširjanje knjižnice z različnimi shemami ponovnega vzorčenja, ki jih lahko uporabnik doda tudi sam z izpeljavo abstraktnega razreda **Resampler**.

Izsek 1 prikazuje izračun zgornjega enostranskega 95-% intervala zaupanja za vzorčno povprečje z dvojno percentilno metodo. Za shemo ponovnega vzorčenja uporabimo osnovni neparametrični postopek za i.i.d. podatke. Na obeh nivojih uporabimo 1000 vzorcev, računanje porazdelimo med 5 procesov, z vektorizacijo pa omogočimo hkraten izračun statistike na več vzorcih bootstrap.

**Izsek kode 1.** Izračun zgornjega enostranskega 95-% intervala zaupanja z dvojno percentilno metodo.

```
# data je polje NumPy
resampler = IIDResampler(data_sample=data)
boot = Bootstrap(
    statistic=np.mean,
    resampler=resampler,
    vectorized=True,
)

# B = 1000, C = 1000
ci = boot.double_percentile_ci(
    confidence_level=0.95,
    side="upper",
    b1_resamples=1000,
    b2_resamples=1000,
    n_jobs=5,
    seed=42,
)
```

**2.2.2. Implementirane sheme ponovnega vzorčenja.** Knjižnica podpira osnovni neparametrični postopek ponovnega vzorčenja i.i.d. podatkov ter neparametrično metodo primerov (angl. *cases bootstrap*) [8, razd. 11.3.3] za hierarhične podatke. Pri slednji skupine na posameznih nivojih hierarhije vzorčimo z ali brez vračanja. Postopek nadaljujemo, dokler ne pridemo do posameznih primerov, ki jih lahko prav tako vzorčimo z ali brez vračanja. V primeru neuravnoteženih skupin lahko ta shema vodi do vzorcev, ki niso velikosti  $n$ .

Za stacionarne časovne vrste smo implementirali štiri neparametrične metode, ki časovno odvisnost med opazovanji poskušajo ohraniti tako, da namesto posameznih opazovanj vzorčijo bloke zaporednih opazovanj.

- *Bootstrap z neprekrivajočimi se bloki* (angl. *non-overlapping block bootstrap*) [21] vzorči iz množice  $[n / l]$  neprekrivajočih se blokov dolžine  $l$ .
- *Bootstrap s premičnimi bloki* (angl. *moving block bootstrap*) [22] vzorči iz množice  $n - l + 1$  prekrivajočih se blokov dolžine  $l$ .
- *Bootstrap s krožnimi bloki* (angl. *circular block bootstrap*) [23] konec časovne vrste poveže z njenim začetkom, kar omogoča izbiro med  $n$  prekrivajočimi se bloki dolžine  $l$ .
- *Stacionarni bootstrap* (angl. *stationary bootstrap*) [24] ne uporablja blokov fiksne dolžine, temveč je njihova dolžina  $L$  geometrijsko porazdeljena slučajna spremenljivka, za katero velja  $\mathbb{E}[L] = l$ . Če blok preseže konec časovne vrste, se tako kot pri bootstrapu s krožnimi bloki nadaljuje na njenem začetku.

Pri vseh štirih metodah začetne indekse blokov vzorčimo neodvisno iz diskretne enakomerne porazdelitve. V naši implementaciji pri metodah s fiksnimi dolžinami blokov vzorčimo  $[n / l]$  blokov, pri stacionarnem bootstrapu pa bloke vzorčimo, dokler dolžina ponovno vzorčene vrste ne doseže ali preseže  $n$ . Na koncu združeni vzorec skrajšamo na dolžino  $n$ .

### 3. Empirična validacija

Da bi empirično ovrednotili skladnost razvite implementacije dvojne percentilne metode z obstoječo rešitvijo, smo izvedli simulacijsko študijo. Za referenčno implementacijo smo uporabili knjižnico **bootstrap-ci**.

**3.1. Zasnova simulacijske študije.** Simulacijska študija se zgleduje po [11]. Eksperiment zajema velikosti vzorca  $n \in \{8, 32, 128\}$  ter statistične funkcionalne pričakovano vrednost (**mean**), mediano (**median**) in Pearsonov koeficient korelacije (**corr**). Vzorce smo generirali iz naslednjih porazdelitev:

- $\text{Normal}(\mu, \sigma^2)$  z  $\mu = 0$  in  $\sigma = 1$  (**Norm**),
- $\text{Exponential}(\lambda)$  z  $\lambda = 1$  (**Exp**),
- $\text{Lognormal}(\mu, \sigma^2)$  z  $\mu = 0$  in  $\sigma = 1$  (**LogNorm**),
- $\text{Normal}(\mu, \Sigma)$  z  $\mu = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$  in  $\Sigma = \begin{bmatrix} 2 & 0,5 \\ 0,5 & 1 \end{bmatrix}$  (**BiNorm**).

Pri enorazsežnih porazdelitvah smo obravnavali pričakovano vrednost in mediano, Pearsonov koeficient korelacije pa nastopa izključno z bivariatno normalno porazdelitvijo. Za vsako kombinacijo porazdelitve, statističnega funkcionala in velikosti vzorca smo generirali  $R = 1000$  neodvisnih vzorcev, v posamezni ponovitvi pa sta obe knjižnici prejeli isti vzorec. Na vsakem vzorcu smo izračunali meji dvojnega percentilnega intervala pri  $\gamma \in \{0,025; 0,975\}$ . Na obeh nivojih dvojne percentilne metode smo uporabili 1000 vzorcev bootstrap, torej  $B = C = 1000$ .

Obravnavali smo naslednje intervale:

$$[\hat{\theta}_{\text{db}}[0,025], \infty), \quad (-\infty, \hat{\theta}_{\text{db}}[0,975]], \quad [\hat{\theta}_{\text{db}}[0,025], \hat{\theta}_{\text{db}}[0,975]].$$

Prvi je enostranski spodnji, drugi enostranski zgornji, tretji pa dvostranski interval.

Pri oceni intervala za Pearsonov koeficient korelacije za  $n = 8$  v dveh ponovitvah zaradi deljenja z nič ni bilo mogoče izračunati intervala zaupanja. Za to nastavitev smo zato ohranili  $R = 998$  ponovitev, pri katerih sta obe implementaciji vrnila veljaven rezultat.

**3.2. Primerjava verjetnosti pokritja.** Verjetnost pokritja posamezne implementacije smo ocenili z deležem intervalov, ki so vsebovali pravo vrednost parametra:

$$\hat{\pi} = \frac{1}{R} \sum_{i=1}^R \mathbf{1}_{\{\theta \in \mathcal{I}(\mathbf{x}_i)\}},$$

kjer je  $\mathcal{I}(\mathbf{x}_i)$  interval, zgrajen na podlagi  $i$ -tega vzorca.

Ker sta implementaciji v posamezni ponovitvi prejeli isti vzorec, smo njuno ujemanje ocenjevali s parno razliko indikatorjev pokritja. Za  $i$ -to ponovitev označimo

$$d_{\pi,i} := \mathbf{1}_{\{\theta \in \mathcal{I}_{\text{our}}(\mathbf{x}_i)\}} - \mathbf{1}_{\{\theta \in \mathcal{I}_{\text{ref}}(\mathbf{x}_i)\}}.$$

Ocenjena razlika verjetnosti pokritja je tedaj

$$d_{\pi} := \hat{\pi}_{\text{our}} - \hat{\pi}_{\text{ref}} = \frac{1}{R} \sum_{i=1}^R d_{\pi,i}. \quad (4)$$

Pozitivna vrednost izraza v enačbi (4) pomeni, da je naša implementacija v obravnavani nastavitvi dosegla večjo ocenjeno verjetnost pokritja, negativna vrednost pa pomeni, da je večjo ocenjeno verjetnost pokritja dosegla referenčna implementacija. Vrednost 0 pomeni enako ocenjeno verjetnost pokritja.


Poleg točkovne ocene smo za vsako kombinacijo izračunali tudi 95-% interval zaupanja  $\text{BC}_a$  za razliko verjetnosti pokritja. Pri tem smo ponovno vzorčili razlike indikatorjev  $d_i$ , kar je ekvivalentno ponovnemu vzorčenju parov indikatorjev. Za izračun posameznega intervala  $\text{BC}_a$  smo uporabili 10.000 vzorcev bootstrap.

Ocenjene razlike v verjetnosti pokritja so pri vseh obravnavanih kombinacijah po absolutni vrednosti manjše od ene odstotne točke. Povprečna razlika znaša  $-0,02$ , povprečna absolutna razlika  $0,23$ , največja absolutna razlika pa  $0,9$  odstotne točke. Rezultati ne kažejo enotne smeri odstopanja, kjer bi katera izmed implementacij imela sistematično večjo oziroma nižjo verjetnost pokritja. Od 63 izračunanih intervalov zaupanja jih 5 ne vključuje vrednosti nič. Podrobnejši povzetek rezultatov primerjave je prikazan v tabeli 1, grafično pa so rezultati prikazani na sliki 1. Točke predstavljajo ocenjene razlike v verjetnosti pokritja v odstotnih točkah, vodoravne črte pa pripadajoče 95-% intervale zaupanja  $\text{BC}_a$ .

Rezultati pri obravnavanih porazdelitvah, velikostih vzorcev in statističnih funkcionalih empirično podpirajo skladnost razvite in referenčne implementacije, kar se tiče pokritja, ki je v tej validaciji najpomembnejši indikator pravilnosti implementacije.

**Tabela 1.** Povzetek razlik v ocenjeni verjetnosti pokritja med razvito in referenčno implementacijo. Vse razlike so izražene v odstotnih točkah. Zadnji stolpec predstavlja število intervalov zaupanja  $BC_\alpha$ , ki ne vključujejo vrednosti nič.

| Tip intervala       | $\bar{d}_\pi$ | $ \bar{d}_\pi $ | $\text{med}( d_\pi )$ | $\max  d_\pi $ | IZ brez 0 |
|---------------------|---------------|-----------------|-----------------------|----------------|-----------|
| Enostranski spodnji | -0,11         | 0,27            | 0,30                  | 0,60           | 4/21      |
| Enostranski zgornji | 0,08          | 0,18            | 0,20                  | 0,50           | 0/21      |
| Dvostranski         | -0,03         | 0,23            | 0,10                  | 0,90           | 1/21      |
| Skupaj              | -0,02         | 0,23            | 0,20                  | 0,90           | 5/63      |



**Slika 1.** Razlika v ocenjeni verjetnosti pokritja med razvito in referenčno knjižnico v odstotnih točkah. Točke predstavljajo ocenjene razlike v verjetnosti pokritja med implementacijama, vodoravne črte pa pripadajoče 95-% intervale zaupanja  $BC_\alpha$ . Navpična črta pri 0 označuje enako pokritje naše in referenčne implementacije.

**3.3. Primerjava mej enostranskih intervalov.** Razliko med ocenjenima mejama intervalov smo za vsako kombinacijo in  $i$ -ti izvorni vzorec definirali kot

$$d_{\gamma,i} := \hat{\theta}_{\text{db},i}^{(\text{our})}[\gamma] - \hat{\theta}_{\text{db},i}^{(\text{ref})}[\gamma].$$

Povprečno razliko med mejama smo ocenili z

$$\bar{d}_\gamma := \frac{1}{R} \sum_{i=1}^R d_{\gamma,i}. \quad (5)$$

Pozitivna vrednost izraza v enačbi (5) pomeni, da je meja, izračunana z našo implementacijo, v povprečju ležala višje od meje referenčne implementacije. Negativna vrednost pomeni, da je v povprečju ležala nižje, vrednost nič pa, da med implementacijama ni bilo povprečnega predznačenega odmika.

## Literatura

1. Wasserman L (2004) *All of Statistics: A Concise Course in Statistical Inference*. (Springer New York, New York, NY).
2. Casella G, Berger RL (2002) *Statistical Inference*. (Duxbury, Pacific Grove, CA), 2 edition.
3. Efron B (1979) Bootstrap Methods: Another Look at the Jack-knife. *The Annals of Statistics* 7(1):1 – 26.
4. Efron B, Tibshirani RJ (1993) *An introduction to the bootstrap*, Chapman Hall/CRC monographs on statistics and applied probability. (Chapman and Hall, London).
5. Efron B (1981) Nonparametric standard errors and confidence intervals. *Canadian Journal of Statistics* 9(2):139–158.
6. Hyndman RJ, Fan Y (1996) Sample quantiles in statistical packages. *The American Statistician* 50(4):361–365.
7. Lahiri SN (2003) *Resampling Methods for Dependent Data*. (Springer New York, New York, NY).
8. Leeden Rvd, Meijer E, Busing FM (2008) *Resampling Multilevel Models*, eds. Leeuw Jd, Meijer E. (Springer New York, New York, NY), pp. 401–433.
9. Hall P (1992) *The bootstrap and Edgeworth expansion*, Springer series in statistics. (Springer-Verlag, New York ).
10. Hall P (1988) Theoretical Comparison of Bootstrap Confidence Intervals. *The Annals of Statistics* 16(3):927 – 953.
11. Zrimšek U, Štrumbelj E (2026) Quantifying uncertainty: all we need is the bootstrap? *Journal of Statistical Computation and Simulation* 96(4):1009–1027.
12. Davison AC, Hinkley DV (1997) *Bootstrap Methods and their Application*, Cambridge Series in Statistical and Probabilistic Mathematics. (Cambridge University Press).
13. Beran R (1987) Prepivoting to reduce level error of confidence sets. *Biometrika* 74(3):457–468.
14. Virtanen P et al. (2020) SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods* 17:261–272.
15. Sheppard K et al. (2015) bashtage/arch.
16. Zrimšek U (2023) bootstrap-ci.
17. Lam SK, Pitrou A, Seibert S (2015) Numba: a llvm-based python jit compiler in *Proceedings of the Second Workshop on the LLVM Compiler Infrastructure in HPC*, LLVM '15. (Association for Computing Machinery, New York, NY, USA).
18. Harris CR et al. (2020) Array programming with NumPy. *Nature* 585(7825):357–362.
19. Wes McKinney (2010) Data Structures for Statistical Computing in Python in *Proceedings of the 9th Python in Science Conference*, eds. Stéfan van der Walt, Jarrod Millman. pp. 56 – 61.
20. The joblib developers (2025) joblib.
21. Carlstein E (1986) The Use of Subseries Values for Estimating the Variance of a General Statistic from a Stationary Sequence. *The Annals of Statistics* 14(3):1171 – 1179.
22. Kunsch HR (1989) The Jackknife and the Bootstrap for General Stationary Observations. *The Annals of Statistics* 17(3):1217 – 1241.
23. Politis DN, Romano JP (1992) A circular block-resampling procedure for stationary data in *Exploring the Limits of Bootstrap*, eds. LePage R, Billard L. (John Wiley & Sons, New York), pp. 263–270.
24. Politis DN, Romano JP (1994) The stationary bootstrap. *Journal of the American Statistical Association* 89(428):1303–1313.